



MODELO PREDICTIVO DE ROTACIÓN DE PERSONAL PARA LA ANTICIPACIÓN DE SALIDAS EN UNA CONSULTORA

PROGRAMA EN PYTHON



DANIEL GRANADOS VALENTIN

9 DE MAYO DE 2026

UTEC - LIMA

Tabla de contenido

CAPÍTULO I: INTRODUCCIÓN	3
1.1 Contexto	3
1.2 Problema	4
1.3 Objetivos	4
1.3.1 Objetivo General	4
1.3.2 Objetivos Específicos	4
CAPÍTULO II: SITUACIÓN INICIAL (AS-IS)	6
2.1 Descripción del proceso	6
2.2 Actividades del proceso	6
2.3 Problemas identificados	7
CAPÍTULO III: EVOLUCIÓN TECNOLÓGICA O SOLUCIÓN PROPUESTA	9
3.1 Fases de desarrollo	9
3.2 Tecnologías seleccionadas	11
3.3 Arquitectura de alto nivel	12
CAPÍTULO IV: ARQUITECTURA TÉCNICA	14
4.1 Lenguaje y entorno de desarrollo	14
4.2 Flujo de datos	15
4.4 Librerías utilizadas	18
CAPÍTULO V: RESULTADOS	19
5.1 Diagrama de flujo de la solución final (TO-BE)	19
5.3 KPIs alcanzados	22
5.4 Tabla comparativa AS-IS vs TO-BE	23
CAPÍTULO VI: CONCLUSIONES Y RECOMENDACIONES	25
6.1 Conclusiones	25
6.2 Limitaciones del proyecto	26
6.3 Recomendaciones y trabajo futuro	27
CAPÍTULO VII: BIBLIOGRAFÍA	30
7.1 Referencias bibliográficas	30
CAPÍTULO VIII: ANEXOS	31
8.1 Código fuente del modelo predictivo	31
8.2 Dataset utilizado	32

8.3 Capturas de resultados	33
8.4 Diccionario de datos	34
8.5 Glosario de términos.....	34

CAPÍTULO I: INTRODUCCIÓN

1.1 Contexto

En el entorno empresarial actual, las organizaciones dedicadas a servicios de consultoría enfrentan el reto permanente de gestionar adecuadamente su capital humano, debido a que el conocimiento, la experiencia y las capacidades técnicas del personal constituyen activos esenciales para garantizar la continuidad operativa y el cumplimiento de los compromisos adquiridos con los clientes. En este contexto, la rotación de personal representa uno de los principales factores de riesgo, ya que puede afectar la estabilidad de los equipos de trabajo, incrementar costos operativos y generar dificultades en la ejecución de proyectos.

Las consultoras suelen operar mediante esquemas dinámicos donde los profesionales participan en distintos proyectos según requerimientos específicos. Debido a ello, eventos como renuncias voluntarias, culminación de contratos o desvinculaciones inesperadas pueden ocasionar retrasos, sobrecarga de funciones y necesidad de reasignación inmediata de recursos humanos. Adicionalmente, los procesos de reclutamiento y capacitación suelen requerir tiempo, lo que incrementa el impacto organizacional cuando no existe capacidad de anticipación.

Tradicionalmente, muchas organizaciones realizan seguimiento a este fenómeno mediante reportes descriptivos elaborados en hojas de cálculo o revisiones periódicas de indicadores históricos. Sin embargo, este enfoque se caracteriza por ser reactivo, dado que permite analizar situaciones ya ocurridas, pero presenta limitaciones para prever comportamientos futuros relacionados con la salida del personal.

En los últimos años, el uso de técnicas de analítica de datos y Machine Learning ha cobrado relevancia dentro de la gestión organizacional, permitiendo transformar información histórica en herramientas de apoyo para la toma de decisiones. En particular, los modelos predictivos posibilitan identificar patrones y tendencias con el propósito de anticipar escenarios futuros y facilitar una planificación más eficiente.

Bajo esta perspectiva, el presente proyecto plantea el diseño de un modelo predictivo orientado a estimar el volumen de rotación de personal en una consultora, utilizando información histórica de desvinculaciones registradas diariamente. La finalidad no consiste en identificar qué trabajador abandonará la organización, sino en proyectar la cantidad aproximada de salidas esperadas durante un periodo determinado, permitiendo a las áreas responsables implementar medidas preventivas relacionadas con contratación, redistribución de personal y continuidad operativa.

1.2 Problema

Dentro de las organizaciones consultoras, la gestión del personal constituye un factor determinante para mantener la continuidad de los servicios ofrecidos. No obstante, una de las principales dificultades identificadas radica en la limitada capacidad para anticipar la salida de colaboradores, especialmente en escenarios donde la desvinculación ocurre de forma inesperada o en volúmenes superiores a los previstos.

Actualmente, el monitoreo de la rotación suele efectuarse mediante revisiones manuales de registros históricos, reportes internos y análisis descriptivos realizados después de ocurrido el evento. Esta práctica impide desarrollar mecanismos preventivos capaces de advertir tendencias de incremento en la salida del personal, generando consecuencias operativas y administrativas relevantes.

Entre las principales afectaciones asociadas a esta situación se encuentran la interrupción parcial de actividades, la redistribución no planificada de recursos humanos, el aumento de la carga laboral sobre otros colaboradores y mayores tiempos de respuesta para cubrir posiciones vacantes. Asimismo, la ausencia de herramientas predictivas limita la capacidad del área de gestión humana para planificar estrategias de retención o contratación anticipada.

A partir de esta problemática surge la necesidad de implementar una alternativa tecnológica que permita aprovechar la información histórica disponible para estimar tendencias futuras de rotación, reduciendo el nivel de incertidumbre en la planificación del personal.

En consecuencia, la pregunta principal que orienta el presente trabajo es la siguiente:

¿De qué manera un modelo predictivo basado en Machine Learning puede contribuir a anticipar el comportamiento de la rotación de personal en una consultora, utilizando información histórica de desvinculaciones laborales?

1.3 Objetivos

1.3.1 Objetivo General

Desarrollar un modelo predictivo basado en técnicas de Machine Learning que permita estimar la rotación de personal en una consultora, utilizando datos históricos de desvinculación para apoyar la toma de decisiones relacionadas con la planificación de recursos humanos.

1.3.2 Objetivos Específicos

OE1. Analizar la información histórica relacionada con la salida de colaboradores para identificar patrones de comportamiento y tendencias temporales.

OE2. Diseñar e implementar un modelo de regresión lineal que permita generar proyecciones sobre el volumen esperado de rotación de personal.

OE3. Visualizar los resultados obtenidos mediante gráficos y tablas comparativas que faciliten la interpretación de las predicciones realizadas.

OE4. Evaluar la utilidad del modelo como herramienta de apoyo para la planificación operativa y la gestión preventiva del talento humano.

OE5. Proponer oportunidades de mejora para fortalecer el desempeño predictivo mediante la incorporación de nuevas variables y técnicas analíticas más avanzadas.

CAPÍTULO II: SITUACIÓN INICIAL (AS-IS)

2.1 Descripción del proceso

Antes de la implementación de una solución analítica, la gestión de rotación de personal dentro de la consultora se desarrollaba principalmente bajo un enfoque reactivo. El seguimiento de salidas laborales se realizaba utilizando registros históricos almacenados en archivos internos, reportes del área de Recursos Humanos y hojas de cálculo empleadas para consolidar información de renuncias, culminación de contratos y desvinculaciones.

El procedimiento existente permitía conocer cuántos trabajadores abandonaban la organización en determinados periodos; sin embargo, no brindaba la capacidad de anticipar tendencias futuras ni identificar posibles incrementos en el volumen de salidas. Como resultado, la planificación de recursos humanos dependía mayormente de la experiencia del personal administrativo y de revisiones periódicas de comportamiento histórico.

Cuando se producía un incremento inesperado de rotación, el área responsable debía reaccionar rápidamente para cubrir vacantes, redistribuir funciones o iniciar nuevos procesos de contratación, lo cual generaba retrasos operativos y sobrecarga laboral en determinados equipos.

El flujo operativo del proceso inicial puede describirse de la siguiente manera:

Proceso AS-IS (Sin automatización predictiva)




Figura 1. Flujo del proceso actual de monitoreo de rotación de personal sin mecanismos predictivos.

2.2 Actividades del proceso

La gestión previa a la implementación tecnológica involucraba distintas actividades manuales realizadas por el área de Recursos Humanos y supervisores administrativos. A continuación, se presenta el detalle del procedimiento operativo.

Actividad	Descripción	Responsable	Herramientas/Sistemas
Registro de salida	Se documentan renuncias, culminaciones contractuales o desvinculaciones	Recursos Humanos	Correo electrónico, documentos internos
Consolidación de datos	Se recopila información histórica de salidas	Analista de RRHH	Microsoft Excel
Elaboración de reportes	Se generan resúmenes de comportamiento histórico	RRHH	Excel
Revisión de tendencias	Se interpreta manualmente el comportamiento de salidas	Jefatura de RRHH	Reportes internos
Planificación operativa	Se ejecutan acciones correctivas ante faltante de personal	Supervisores / Gestión Humana	Correo, reuniones operativas

En términos generales, el proceso dependía considerablemente de la intervención manual, lo cual limitaba la capacidad de respuesta ante escenarios de alta rotación.

Asimismo, el uso predominante de herramientas tradicionales dificultaba la detección temprana de patrones de comportamiento, dado que los análisis realizados se centraban únicamente en información retrospectiva.

2.3 Problemas identificados

Como resultado del análisis del proceso actual, se identificaron diversas limitaciones operativas y analíticas que afectan la gestión eficiente del talento humano.

a) Ausencia de capacidad predictiva

El principal problema identificado radica en que la organización no dispone de mecanismos tecnológicos orientados a anticipar posibles incrementos en la salida de colaboradores.

La revisión de información histórica permite únicamente observar comportamientos ya ocurridos, imposibilitando ejecutar medidas preventivas antes de que el problema impacte directamente en la operación.

b) Dependencia de procesos manuales

El procesamiento de información se realiza principalmente mediante hojas de cálculo y consolidaciones manuales, lo cual incrementa el tiempo requerido para generar reportes y aumenta la probabilidad de inconsistencias en los datos.

c) Reacción tardía ante incrementos de rotación

Debido a la falta de alertas o proyecciones futuras, la organización responde cuando el déficit de personal ya se encuentra presente, generando dificultades como:

- Sobrecarga laboral en equipos existentes.
- Retrasos en actividades operativas.
- Incremento en tiempos de contratación.
- Reasignación no planificada de personal.

d) Limitada toma de decisiones basada en datos

La planificación de recursos humanos se sustenta principalmente en observaciones históricas y experiencia operativa, reduciendo la capacidad de construir estrategias preventivas fundamentadas en evidencia cuantitativa.

Cuadro resumen de problemas identificados

Problema	Impacto identificado	Nivel de afectación
Falta de predicción	No se anticipan picos de salida	Alto
Gestión manual	Mayor tiempo de análisis	Medio
Reacción tardía	Cobertura lenta de vacantes	Alto
Escasa analítica	Decisiones menos precisas	Medio

A partir de estas limitaciones surge la necesidad de implementar una solución basada en analítica predictiva que permita transformar los datos históricos en información de valor para la gestión preventiva del personal, reduciendo incertidumbre y fortaleciendo la capacidad de planificación organizacional.

CAPÍTULO III: EVOLUCIÓN TECNOLÓGICA O SOLUCIÓN PROPUESTA

3.1 Fases de desarrollo

Con el propósito de atender las limitaciones identificadas en el proceso actual de monitoreo de rotación de personal, se diseñó una solución tecnológica orientada al análisis predictivo mediante técnicas de Machine Learning. El desarrollo del proyecto se ejecutó de manera incremental, permitiendo validar progresivamente los resultados obtenidos y asegurar coherencia entre la problemática identificada y la solución implementada.

La evolución del proyecto se estructuró en distintas fases de trabajo, las cuales abarcaron desde el entendimiento del problema hasta la generación de predicciones y visualizaciones analíticas.

Fase 1: Identificación del problema y entendimiento del contexto

En la etapa inicial se realizó el análisis de la problemática organizacional vinculada a la dificultad para anticipar la salida de personal dentro de la consultora.

Durante esta fase se identificaron los principales impactos asociados a la rotación laboral, tales como:

- Interrupciones operativas.
- Dificultades en la continuidad de proyectos.
- Sobrecarga de trabajo en equipos existentes.
- Necesidad de contratación no planificada.

Asimismo, se definió el alcance del proyecto, delimitando el análisis hacia la estimación del volumen diario de desvinculaciones y no hacia la predicción individual de empleados.

Resultado de la fase:

Definición del problema de negocio y planteamiento del enfoque predictivo.

Fase 2: Recolección y preparación de datos

Posteriormente, se trabajó con una base de datos simulada compuesta por **180 días de registros históricos de rotación diaria**, construida con un comportamiento estadístico similar a escenarios reales de organizaciones de consultoría.

La variable objetivo considerada fue:

Empleados_Rotados, correspondiente a la cantidad de colaboradores que abandonaron la organización diariamente.

Durante esta etapa se realizaron actividades de:

- Validación de estructura de datos.
- Revisión de consistencia.
- Organización cronológica de registros.
- Preparación de variables para entrenamiento.

Debido al alcance del proyecto, se optó por utilizar una serie temporal simple sin incorporar variables exógenas como desempeño, antigüedad o área organizacional.

Resultado de la fase:

Conjunto de datos preparado para el entrenamiento del modelo predictivo.

Fase 3: Diseño e implementación del modelo predictivo

En esta etapa se seleccionó un enfoque de **regresión lineal simple**, debido a su facilidad interpretativa, bajo nivel de complejidad y utilidad para detectar tendencias crecientes o decrecientes dentro de series temporales.

El modelo fue configurado utilizando:

- **Variable independiente (X):** número de días transcurridos desde el inicio del registro.
- **Variable dependiente (y):** cantidad de empleados desvinculados por día.

El entrenamiento del algoritmo se efectuó utilizando la totalidad de los datos históricos disponibles, permitiendo identificar el comportamiento general de la rotación observada.

Posteriormente, el modelo generó estimaciones correspondientes a los **30 días posteriores al periodo histórico registrado**.

Resultado de la fase:

Modelo funcional capaz de producir predicciones de corto plazo.

Fase 4: Visualización y análisis de resultados

Finalmente, se implementó una etapa orientada a la interpretación visual de la información obtenida.

Los resultados fueron representados mediante:

- Tabla comparativa entre valores históricos y proyecciones.

- Gráfico de líneas con comportamiento temporal.
- Segmentación visual entre datos reales y predichos.

La representación gráfica permitió identificar de forma más intuitiva posibles tendencias de incremento en la rotación y facilitar la interpretación por parte de usuarios no técnicos.

Resultado de la fase:

Visualización comprensible para apoyar decisiones relacionadas con planificación de personal.

3.2 Tecnologías seleccionadas

La implementación de la solución requirió el uso de herramientas orientadas al procesamiento de datos, modelamiento predictivo y visualización de información.

La selección tecnológica se realizó considerando factores como facilidad de implementación, accesibilidad, disponibilidad de documentación y compatibilidad con proyectos analíticos.

Python

Se eligió Python como lenguaje principal debido a su amplia adopción dentro del ámbito de ciencia de datos y Machine Learning.

Entre sus principales ventajas destacan:

- Sintaxis clara y fácil mantenimiento.
- Amplio ecosistema de librerías analíticas.
- Integración eficiente para procesamiento y modelamiento de datos.
- Alta adopción académica y empresarial.

Pandas

La librería Pandas fue utilizada para la manipulación y estructuración de datos.

Permitió:

- Leer información tabular.
- Organizar registros cronológicos.
- Gestionar estructuras tipo DataFrame.
- Facilitar transformaciones previas al modelamiento.

NumPy

Se utilizó NumPy para operaciones numéricas relacionadas con el manejo eficiente de arreglos y cálculos matemáticos requeridos durante el procesamiento.

Scikit-learn

La construcción del modelo predictivo se realizó utilizando la librería Scikit-learn, debido a:

- Facilidad de implementación.
- Disponibilidad de algoritmos supervisados.
- Bajo nivel de complejidad de integración.
- Documentación ampliamente disponible.

En particular, se utilizó el algoritmo de **Linear Regression**.

Matplotlib

La visualización de resultados se desarrolló mediante Matplotlib, permitiendo generar gráficos de líneas para representar:

- Datos históricos.
- Tendencias observadas.
- Predicciones futuras.

Justificación tecnológica

Las tecnologías seleccionadas permitieron desarrollar una solución de bajo costo de implementación, fácilmente reproducible y adecuada para fines académicos y organizacionales.

Asimismo, ofrecen escalabilidad para futuras mejoras orientadas a modelos más sofisticados de análisis predictivo.

3.3 Arquitectura de alto nivel

La arquitectura propuesta fue diseñada bajo un enfoque simple orientado al procesamiento secuencial de datos, permitiendo transformar información histórica en predicciones visualmente interpretables.

El flujo general de funcionamiento de la solución puede describirse de la siguiente manera:

Arquitectura de alto nivel




Figura 2. Arquitectura de alto nivel de la solución predictiva propuesta.

Esta arquitectura permite transformar datos históricos en información analítica útil, reduciendo el nivel de incertidumbre asociado a la planificación de recursos humanos y fortaleciendo la capacidad de anticipación frente a posibles incrementos en la rotación laboral.

CAPÍTULO IV: ARQUITECTURA TÉCNICA

4.1 Lenguaje y entorno de desarrollo

La implementación del modelo predictivo se realizó utilizando el lenguaje de programación **Python**, seleccionado por su amplio uso en proyectos relacionados con análisis de datos, automatización y Machine Learning. Su ecosistema de librerías permite desarrollar soluciones analíticas de forma eficiente, reduciendo tiempos de implementación y facilitando la reutilización del código.

Para el desarrollo del proyecto se empleó un entorno local de ejecución compatible con herramientas de análisis de datos, permitiendo la integración de librerías especializadas para procesamiento, modelamiento y visualización.

Configuración del entorno tecnológico

Componente	Descripción
Lenguaje de programación	Python
Entorno de ejecución	Colab / Visual Studio Code
Gestión de dependencias	pip
Sistema operativo	Windows
Tipo de solución	Modelo predictivo local

Versiones utilizadas

Se trabajó con un entorno compatible con versiones recientes de Python, asegurando compatibilidad entre dependencias y estabilidad en la ejecución.

Configuración referencial del entorno:

- Python 3.11 o superior
- Pandas 2.x
- Scikit-learn 1.x
- NumPy 1.x
- Matplotlib 3.x

La selección de estas herramientas respondió a criterios de accesibilidad, facilidad de implementación y bajo costo de despliegue, considerando que el objetivo principal del proyecto consistía en validar un modelo predictivo funcional aplicable a escenarios organizacionales.

4.2 Flujo de datos

El procesamiento de información siguió un flujo secuencial orientado a convertir datos históricos en predicciones futuras de rotación de personal. Cada etapa cumplió una función específica dentro del proceso analítico.

Etapas 1: Lectura de datos

Inicialmente, se cargó una base de datos histórica que contenía registros diarios de rotación laboral correspondientes a un periodo de **180 días**.

La estructura principal estuvo conformada por:

- Fecha del registro.
- Cantidad de empleados desvinculados por día.

El conjunto de datos fue diseñado para representar un comportamiento similar al observado en escenarios organizacionales reales.

Etapas 2: Limpieza y validación

Posteriormente, se efectuó un proceso de revisión de consistencia para asegurar la calidad de los datos utilizados.

Las actividades realizadas incluyeron:

- Validación de registros vacíos.
- Revisión de estructura cronológica.
- Verificación de formato de fechas.
- Confirmación de integridad de la variable objetivo.

Debido a que la información utilizada fue previamente estructurada, el nivel de transformación requerido fue reducido.

Etapas 3: Transformación de variables

Con el propósito de entrenar el algoritmo de regresión lineal, fue necesario transformar la dimensión temporal en una variable numérica interpretable por el modelo.

Se definieron las siguientes variables:

Variable independiente (X):

Número consecutivo de días desde el inicio del registro histórico.

Variable dependiente (y):

Cantidad de empleados desvinculados diariamente.

Esta transformación permitió representar matemáticamente la evolución de la rotación laboral en función del tiempo.

Etapas 4: Entrenamiento del modelo

El algoritmo fue entrenado utilizando los registros históricos disponibles con el objetivo de identificar la relación existente entre el transcurso del tiempo y la variación observada en las salidas de personal.

El modelo buscó detectar una tendencia general de comportamiento para posteriormente extrapolar estimaciones futuras.

Etapas 5: Predicción

Una vez entrenado el algoritmo, se procedió a generar predicciones correspondientes a los **30 días posteriores** al periodo histórico.

Las estimaciones producidas permitieron proyectar el posible volumen diario de desvinculaciones esperadas.

Etapas 6: Visualización de resultados

Finalmente, los resultados obtenidos fueron representados mediante gráficos y tablas comparativas con el propósito de facilitar su interpretación.

Las visualizaciones incluyeron:

- Línea de comportamiento histórico.
- Línea de proyección futura.
- Separación visual entre datos reales y estimados.

Flujo general de datos




Figura 3. Flujo técnico de procesamiento de datos del sistema predictivo.

4.3 Módulos y scripts

El proyecto fue estructurado de manera modular con la finalidad de separar responsabilidades y facilitar la mantenibilidad del código.

Aunque la solución fue desarrollada inicialmente como un prototipo académico, su organización permite futuras extensiones o automatizaciones.

Estructura lógica del proyecto

Archivo principal de procesamiento

ProyectoFinalUTEC_DanielGranados_Colab.ipynb

Archivo encargado de ejecutar el flujo principal del sistema.

Funciones principales:

- Lectura de dataset.
 - Preparación de datos.
 - Entrenamiento del modelo.
 - Generación de predicciones.
 - Llamado a visualizaciones.
-

Archivo de datos

ProyectoFinalUTEC_DanielGranados_Dataset.xlsx

Repositorio de datos históricos utilizado como entrada del modelo.

Contenido:

- Fechas históricas.
- Cantidad de empleados rotados.

La modularidad planteada favorece la reutilización del código y permite futuras integraciones con dashboards o sistemas de inteligencia empresarial.

4.4 Librerías utilizadas

La implementación requirió distintas librerías orientadas al tratamiento de datos, modelamiento matemático y visualización.

Tabla de librerías implementadas

Librería	Versión referencial	Función dentro del proyecto
Pandas	2.x	Manipulación y análisis de datos
NumPy	1.x	Operaciones matemáticas y arreglos numéricos
Scikit-learn	1.x	Entrenamiento del modelo predictivo
Matplotlib	3.x	Visualización gráfica
OpenPyXL	3.x	Lectura de archivos Excel

Descripción funcional de las librerías

Pandas:

Permitió estructurar los datos históricos en tablas manipulables, facilitando operaciones de filtrado y preparación.

NumPy:

Se utilizó para optimizar cálculos matemáticos relacionados con la transformación de variables.

Scikit-learn:

Librería principal utilizada para construir el algoritmo de regresión lineal empleado en la predicción.

Matplotlib:

Herramienta gráfica utilizada para representar el comportamiento histórico y las estimaciones futuras.

OpenPyXL:

Se empleó para garantizar compatibilidad en la lectura de archivos Excel utilizados como fuente de datos.

La combinación de estas tecnologías permitió construir una solución ligera, reproducible y técnicamente adecuada para abordar el problema planteado desde una perspectiva analítica.

CAPÍTULO V: RESULTADOS

5.1 Diagrama de flujo de la solución final (TO–BE)

Tras la implementación del modelo predictivo, el proceso de monitoreo de rotación de personal evolucionó desde un enfoque reactivo hacia un esquema orientado a la anticipación de escenarios futuros. La nueva propuesta incorpora análisis automatizado de información histórica y generación de predicciones que facilitan la planificación de recursos humanos.

A diferencia del proceso inicial, donde las decisiones dependían exclusivamente de revisiones manuales, la solución implementada permite utilizar datos históricos para proyectar tendencias de salida de colaboradores en periodos posteriores.

El flujo operativo del escenario propuesto se representa de la siguiente manera:

Proceso TO–BE (Con analítica predictiva)




Figura 4. Flujo del proceso futuro incorporando analítica predictiva.

La implementación del nuevo enfoque permite fortalecer la capacidad de anticipación organizacional, reduciendo el nivel de incertidumbre asociado a la disponibilidad de personal.

5.2 Capturas de pantalla de la aplicación

La solución desarrollada generó una salida visual basada en gráficos comparativos y tablas de proyección, permitiendo interpretar de manera sencilla el comportamiento de la rotación laboral.

Vista 1: Tabla comparativa de resultados

La primera salida corresponde a una tabla que compara los últimos registros históricos con las predicciones generadas por el modelo.

Características principales:

- Presenta datos reales de rotación observada.
- Incluye estimaciones para los siguientes 30 días.
- Los resultados se muestran redondeados para facilitar su interpretación.
- Facilita el análisis comparativo entre comportamiento pasado y comportamiento esperado.

Tabla combinada de datos reales y predichos:

Fecha	Rotacion_Real	Empleados_Rotados
2025-09-19 00:13:48	1	
2025-09-20 00:13:48	2	
2025-09-21 00:13:48	1	
2025-09-22 00:13:48	2	
2025-09-23 00:13:48	1	
2025-09-24 00:13:48	3	
2025-09-25 00:13:48	2	
2025-09-26 00:13:48	1	
2025-09-27 00:13:48	2	
2025-09-28 00:13:48	4	
2025-09-29 00:13:48	1	
2025-09-30 00:13:48	2	
2025-10-01 00:13:48	2	
2025-10-02 00:13:48	1	
2025-10-03 00:13:48	4	
2025-10-04 00:13:48	1	
2025-10-05 00:13:48	1	
2025-10-06 00:13:48	1	
2025-10-07 00:13:48	3	
2025-10-08 00:13:48	1	
2025-10-09 00:13:48	4	
2025-10-10 00:13:48	2	
2025-10-11 00:13:48	1	
2025-10-12 00:13:48	2	
2025-10-13 00:13:48	1	

2025-10-14 00:13:48	1	
2025-10-15 00:13:48	1	
2025-10-16 00:13:48	3	
2025-10-17 00:13:48	1	
2025-10-18 00:13:48	2	
2025-10-19 00:13:48		2
2025-10-20 00:13:48		2
2025-10-21 00:13:48		2
2025-10-22 00:13:48		2
2025-10-23 00:13:48		2
2025-10-24 00:13:48		2
2025-10-25 00:13:48		2
2025-10-26 00:13:48		2
2025-10-27 00:13:48		2
2025-10-28 00:13:48		2
2025-10-29 00:13:48		2
2025-10-30 00:13:48		2
2025-10-31 00:13:48		2
2025-11-01 00:13:48		2
2025-11-02 00:13:48		2
2025-11-03 00:13:48		2
2025-11-04 00:13:48		2
2025-11-05 00:13:48		2
2025-11-06 00:13:48		2
2025-11-07 00:13:48		2
2025-11-08 00:13:48		2
2025-11-09 00:13:48		2
2025-11-10 00:13:48		2
2025-11-11 00:13:48		2
2025-11-12 00:13:48		2
2025-11-13 00:13:48		2
2025-11-14 00:13:48		2
2025-11-15 00:13:48		3
2025-11-16 00:13:48		3
2025-11-17 00:13:48		3

Figura 5. Comparación entre registros históricos y valores estimados.


Vista 2: Gráfico predictivo de rotación de personal

La segunda salida visual corresponde a un gráfico de líneas orientado a representar el comportamiento temporal de la variable analizada.

Interpretación del gráfico:

- **Línea azul:** representa los datos históricos de rotación registrados.
- **Línea roja:** representa las predicciones generadas por el modelo.
- **Línea vertical gris:** divide el punto temporal entre información histórica y proyección futura.

El gráfico permite identificar visualmente la existencia de una tendencia creciente en la salida de colaboradores, facilitando la comprensión de resultados incluso para usuarios sin conocimientos técnicos en analítica.



Tiempo de reacción ante salidas	Reactivo	Preventivo	Mejora operativa
Capacidad predictiva	No disponible	Disponible a 30 días	Implementada
Visualización de tendencias	Limitada	Automatizada	Alta

Beneficios observados

La solución permitió:

- Reducir tiempos asociados al análisis manual.
- Facilitar la interpretación del comportamiento histórico.
- Incorporar una capacidad predictiva inexistente previamente.
- Mejorar la planificación del área de Recursos Humanos.
- Reducir el nivel de incertidumbre frente a incrementos de rotación.

Asimismo, el modelo constituye una base inicial para futuras soluciones más sofisticadas relacionadas con retención de talento y análisis organizacional.

5.4 Tabla comparativa AS–IS vs TO–BE

Con el propósito de evidenciar las mejoras introducidas, se presenta una comparación entre el estado inicial del proceso y el escenario posterior a la implementación tecnológica.

Comparativa del antes y después

Dimensión	AS–IS (Situación actual)	TO–BE (Situación propuesta)
Gestión de rotación	Manual	Automatizada parcialmente
Tipo de análisis	Descriptivo	Predictivo
Fuente de decisiones	Experiencia y revisión manual	Datos históricos y proyecciones
Tiempo de análisis	Elevado	Reducido
Anticipación de problemas	No disponible	Disponible
Visualización	Básica	Gráfica y comparativa
Planeamiento de RRHH	Reactivo	Preventivo

Escalabilidad	Limitada	Alta
---------------	----------	------

A partir de esta comparación, se evidencia que la implementación del modelo predictivo aporta mejoras importantes en términos de capacidad analítica, velocidad de respuesta y apoyo a la toma de decisiones organizacionales.

En consecuencia, el nuevo enfoque contribuye a fortalecer la gestión del talento humano, permitiendo a la consultora prepararse de manera anticipada frente a posibles incrementos en la salida de personal.

CAPÍTULO VI: CONCLUSIONES Y RECOMENDACIONES

6.1 Conclusiones

Las conclusiones del presente proyecto se desarrollan en función de los objetivos específicos planteados en el Capítulo I, con el propósito de validar el cumplimiento de los resultados esperados.

Conclusión relacionada con el OE1

(OE1: Analizar la información histórica relacionada con la salida de colaboradores para identificar patrones de comportamiento y tendencias temporales)

El análisis exploratorio de los datos históricos permitió identificar un comportamiento progresivo en la rotación de personal dentro del periodo evaluado. A partir de los registros diarios utilizados, fue posible reconocer una tendencia moderadamente creciente en el volumen de desvinculaciones, evidenciando que la información histórica puede constituir una fuente relevante para comprender patrones organizacionales asociados al movimiento del talento humano.

Asimismo, se comprobó que incluso un conjunto de datos simple puede aportar información útil para apoyar decisiones operativas cuando es procesado bajo un enfoque analítico.

Conclusión relacionada con el OE2

(OE2: Diseñar e implementar un modelo de regresión lineal que permita generar proyecciones sobre el volumen esperado de rotación de personal)

La implementación del modelo de regresión lineal permitió construir una solución predictiva funcional orientada a estimar el comportamiento futuro de la rotación laboral. Los resultados obtenidos demostraron que el algoritmo fue capaz de capturar la tendencia general observada en los datos históricos y producir estimaciones coherentes respecto al comportamiento esperado de las salidas de personal.

Adicionalmente, se evidenció que modelos de baja complejidad pueden representar una alternativa viable en escenarios organizacionales donde se busca interpretabilidad y facilidad de implementación.

Conclusión relacionada con el OE3

(OE3: Visualizar los resultados obtenidos mediante gráficos y tablas comparativas que faciliten la interpretación de las predicciones realizadas)

La representación visual de resultados facilitó significativamente la comprensión de la información generada por el modelo predictivo. El uso de gráficos comparativos permitió distinguir claramente la relación entre datos históricos y predicciones futuras, simplificando el proceso de interpretación para usuarios no especializados en analítica o ciencia de datos.

En consecuencia, las visualizaciones implementadas demostraron ser un mecanismo útil para comunicar resultados de manera clara y apoyar procesos de toma de decisiones.

Conclusión relacionada con el OE4

(OE4: Evaluar la utilidad del modelo como herramienta de apoyo para la planificación operativa y la gestión preventiva del talento humano)

Se determinó que el modelo predictivo posee utilidad práctica como herramienta de soporte para la planificación del área de Recursos Humanos, debido a que permite anticipar posibles incrementos en la salida de colaboradores y reducir el nivel de incertidumbre asociado a la disponibilidad de personal.

Aunque la solución no reemplaza el criterio organizacional, sí representa un mecanismo complementario que puede fortalecer decisiones relacionadas con contratación, redistribución de funciones y continuidad operativa.

Conclusión relacionada con el OE5

(OE5: Proponer oportunidades de mejora para fortalecer el desempeño predictivo mediante la incorporación de nuevas variables y técnicas analíticas más avanzadas)

Se identificó que el desempeño del modelo puede incrementarse mediante la incorporación de variables complementarias relacionadas con características del colaborador y contexto organizacional. Factores como antigüedad laboral, área funcional, desempeño, modalidad contractual o clima organizacional podrían aportar mayor capacidad explicativa al proceso predictivo.

Asimismo, futuras implementaciones podrían incorporar algoritmos más sofisticados orientados a series temporales y aprendizaje profundo, permitiendo incrementar precisión y robustez del sistema.

6.2 Limitaciones del proyecto

Durante el desarrollo de la investigación se identificaron ciertas restricciones metodológicas y técnicas que deben ser consideradas al interpretar los resultados obtenidos.

Limitaciones identificadas

a) Uso de datos simulados

La información utilizada correspondió a una base de datos simulada diseñada para representar un comportamiento organizacional cercano a escenarios reales. Si bien ello permitió validar el funcionamiento del modelo, los resultados no representan un caso empresarial específico.

b) Ausencia de variables externas

El modelo fue desarrollado utilizando únicamente una serie temporal simple, sin incorporar factores adicionales que podrían influir en la rotación de personal, tales como:

- Tipo de contrato.
 - Área organizacional.
 - Antigüedad del colaborador.
 - Evaluación de desempeño.
 - Nivel salarial.
 - Clima laboral.
-

c) Modelo predictivo de complejidad limitada

Se optó por utilizar regresión lineal debido a su facilidad interpretativa y pertinencia académica; sin embargo, este enfoque presenta limitaciones para modelar relaciones no lineales o comportamientos altamente variables.

d) Alcance temporal reducido

La proyección fue realizada únicamente para un horizonte de **30 días**, por lo que los resultados deben interpretarse como estimaciones de corto plazo.

6.3 Recomendaciones y trabajo futuro

Con base en los resultados obtenidos y las limitaciones identificadas, se proponen las siguientes recomendaciones para fortalecer el alcance del sistema predictivo.

Incorporación de nuevas variables

Se recomienda ampliar el conjunto de datos incorporando información organizacional complementaria, debido a que esto podría mejorar la capacidad predictiva del modelo.

Variables sugeridas:

- Tiempo de permanencia del colaborador.
 - Tipo de contrato laboral.
 - Área o unidad organizacional.
 - Resultados de desempeño.
 - Historial de ausentismo.
 - Encuestas de satisfacción laboral.
-

Implementación de modelos más avanzados

Se recomienda explorar algoritmos especializados en series temporales y predicción multivariable, tales como:

- **ARIMA**, para análisis temporal estadístico.
 - **Prophet**, para modelamiento de tendencias y estacionalidad.
 - **Random Forest Regressor**, para relaciones más complejas.
 - **Redes neuronales LSTM**, orientadas a secuencias temporales.
-

Integración con dashboards interactivos

Como línea futura de trabajo, se propone incorporar herramientas de visualización dinámica que permitan monitorear indicadores en tiempo real.

Tecnologías sugeridas:

- Streamlit.
 - Power BI.
 - Dash Plotly.
-

Automatización del flujo analítico

Finalmente, se recomienda automatizar la carga de datos y actualización de predicciones, con el propósito de minimizar intervención manual y asegurar disponibilidad continua de información para la toma de decisiones.

La implementación de estas mejoras permitiría evolucionar el proyecto desde un prototipo académico hacia una herramienta organizacional con mayor impacto operativo y analítico.

CAPÍTULO VII: BIBLIOGRAFÍA

A continuación, se presentan las referencias bibliográficas utilizadas como sustento conceptual, metodológico y técnico del presente proyecto, organizadas bajo el formato APA 7.^a edición.

7.1 Referencias bibliográficas

Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow

Aurélien Géron. (2019). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems* (2nd ed.). O'Reilly Media.

Python for Data Analysis

Wes McKinney. (2018). *Python for data analysis: Data wrangling with Pandas, NumPy, and IPython* (2nd ed.). O'Reilly Media.

Introduction to Machine Learning with Python

Andreas C. Müller, & Sarah Guido. (2016). *Introduction to machine learning with Python: A guide for data scientists*. O'Reilly Media.

[Scikit-learn Documentation](#)

Scikit-learn Developers. (2025). *Scikit-learn user guide*.

[Pandas Documentation](#)

Pandas Development Team. (2025). *Pandas user guide*.

[NumPy Documentation](#)

NumPy Developers. (2025). *NumPy reference guide*.

[Matplotlib Documentation](#)

Matplotlib Development Team. (2025). *Matplotlib visualization guide*.

CAPÍTULO VIII: ANEXOS

8.1 Código fuente del modelo predictivo

En esta sección se incorporará el código desarrollado en Python para el entrenamiento del modelo de regresión lineal, generación de predicciones y construcción de visualizaciones.

Contenido sugerido:

- Lectura de datos.
- Preparación de variables.
- Entrenamiento del modelo.
- Generación de predicciones.
- Construcción de gráficos.

```
###Proyecto final UTEC >>> Daniel Granados Valentin

[3]
✓ #paso 1: Importar librerías necesarias
import pandas as pd                #Manipulación de datos
import numpy as np                 #Cálculo numéricos y arreglos
import matplotlib.pyplot as plt    #Visualización de datos
import seaborn as sns              #Visualización de datos avanzados
from sklearn.linear_model import LinearRegression #Modelo de regresión lineal
from google.colab import files     #Subir archivos desde el navegador

[4]
✓ #Paso 2: Subir el archivo excel con los historicos
uploaded = files.upload()          #Se abre un cuadro para cargar el archivo de excel

[6]
✓ #Paso 3: Leer el archivo cargado y guardarlo en un DataFrame
df = pd.read_excel("ProyectoFinalUTEC_DanielGranados_Dataset.xlsx") #cambia el nombre si tu archivo tiene otro

[7]
✓ #Paso 4: Mostrar los primeros registros a validar
print("Primeros registros del archivo")
print(df.head())

[8]
✓ #Paso 5: Agregar columna días
df['Días'] = np.arange(len(df))    #Secuencia 0,1,2

[9]
✓ #Paso 6: Definir las variables del modelo
X = df[['Días']]                  #Variable independiente en días
y = df['Empleados_Rotados']       #Cantidad de empleados que rotaron por día

[10]
✓ #Paso 7: Crear y entrenar el modelo
modelo = LinearRegression()       #Crear el modelo
modelo.fit(X, y)                  #Entrenar el modelo

[11]
✓ #Paso 8: Crear los próximos 30 días (Como valores X) para predecir
días_futuros = np.arange(len(df),len(df) + 30).reshape(-1,1) #Matriz de 30 días futuros
```



```
[12] ✓ #Paso 9: Realizar las predicciones
predicciones = modelo.predict(dias_futuros) #salida: array de 30 predicciones

[13] ✓ #Paso 10: Crear fechas futuras para asignar las predicciones
fechas_futuros = pd.date_range(start=df['Fecha'].iloc[-1] + pd.Timedelta(days=1), periods=30)

[14] ✓ #Paso 11: Crear el dataframe con las predicciones y redondearlas a enteros
df_pred = pd.DataFrame({
    'Fecha': fechas_futuros, 'Empleados_Rotados': np.round(predicciones).astype(int)
})

[15] ✓ #Paso 12: Extraer ultimos 30 días reales
df_real = df.tail(30)[['Fecha', 'Empleados_Rotados']]
df_real.columns = ['Fecha', 'Rotacion_Real']

[16] ✓ #Paso 13: Combinar datos reales y predichos
df_real.set_index('Fecha', inplace=True)
df_pred.set_index('Fecha', inplace=True)
df_combinado = pd.concat([df_real, df_pred], axis=0)

[17] ✓ #Paso 14: Mostrar la tabla en consola
print("\nTabla combinada de datos reales y predichos:")
print(df_combinado.fillna("-"))

[18] ✓ #Paso 15: Exportar la tabla en excel
df_combinado_export = df_combinado.copy()
df_combinado_export.to_excel("Tabla_rotacion_real_vs_prediccion.xlsx")

[19] ✓ #Paso 16: Descargar archivo de excel
files.download("Tabla_rotacion_real_vs_prediccion.xlsx")

[20] ✓ #Paso 17 Graficar los resultado
plt.figure(figsize=(12, 6))
plt.plot(
    df_combinado.index,
    df_combinado['Rotacion_Real'],
    label='Real(Últimos 30 días)',
    color = 'blue',
    linewidth = 2)
plt.plot(
    df_combinado.index,
    df_combinado['Empleados_Rotados'],
    label='Predicción(Próximos 30 días)',
    color = 'red',
    linewidth = 2)

plt.axvline(x=df_real.index[-1], color='gray', linestyle='--', label='Hoy')

plt.title("Rotación diaria de empleados: Real vs Predicción")
plt.xlabel("Fecha")
plt.ylabel("Empleados Rotados")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```

8.2 Dataset utilizado

Se adjuntará el conjunto de datos empleado durante el desarrollo del proyecto.

Contenido mínimo:

Fecha	Empleados_Rotados
2025-09-19 00:13:48	1
2025-09-20 00:13:48	2
2025-09-21 00:13:48	1
2025-09-22 00:13:48	2
2025-09-23 00:13:48	1
...	...

Dataset histórico:



ProyectoFinalUTEC_
DanielGranados_Da

8.3 Capturas de resultados

Se incluyen evidencias visuales obtenidas durante la ejecución del modelo.

- Captura del dataset cargado:

```
[22] #Paso 2: Subir el archivo excel con los historicos
✓ 10 s uploaded = files.upload() #Se abre un cuadro para cargar el archivo de excel

Elegir archivos ProyectoFin...Dataset.xlsx
ProyectoFinalUTEC_DanielGranados_Dataset.xlsx(application/vnd.openxmlformats-officedocument.spreadsheetml.sheet) - 10798 bytes, last modified: 10/5/2026 - 100% done
Saving ProyectoFinalUTEC_DanielGranados_Dataset.xlsx to ProyectoFinalUTEC_DanielGranados_Dataset (1).xlsx
```

- Captura del gráfico predictivo:



8.4 Diccionario de datos

Se recomienda incorporar un diccionario descriptivo para facilitar la interpretación de variables.

Variable	Tipo	Descripción
Fecha	Date	Día del registro
Empleados_Rotados	Integer	Número de colaboradores que abandonaron la organización

8.5 Glosario de términos

Machine Learning: disciplina orientada al desarrollo de algoritmos capaces de identificar patrones y realizar predicciones basadas en datos históricos.

Regresión lineal: técnica estadística utilizada para modelar relaciones entre variables y estimar comportamientos futuros.

Rotación de personal: movimiento de entrada y salida de colaboradores dentro de una organización.

Predicción: estimación de eventos futuros basada en comportamiento histórico.

Serie temporal: conjunto de datos organizados cronológicamente a lo largo del tiempo.